

Machine Learning con PySpark y Docker

Reporte Ejecutivo - Proyecto Final

Sergio Prieto | Mayo 2026 | Universidad Santo Tomas

1. Resumen Ejecutivo

Este proyecto constituye el componente practico del parcial final del curso Machine Learning con PySpark y Docker. Se desarrollo un analisis completo sobre datos reales colombianos aplicando tecnicas de analisis exploratorio, machine learning supervisado y no supervisado, y procesamiento de lenguaje natural con modelos pre-entrenados. El proyecto se articula en tres bloques que abordan el fenomeno de la vigilancia en salud publica desde diferentes enfoques analiticos, demostrando la integracion de los aprendizajes de los tres cortes del semestre.

2. Datasets Utilizados

Dataset principal — SIVIGILA 2019: Sistema Nacional de Vigilancia en Salud Publica de Colombia. Contiene 205,532 registros de notificaciones obligatorias de 69 tipos de eventos de salud publica reportados en 35 departamentos a lo largo de 52 semanas epidemiologicas durante 2019. Variables: codigo del evento, nombre del evento, ano, semana epidemiologica, codigo de departamento, municipio y conteo de casos.

Corpus textual — PQRS datos.gov.co: Dataset de Peticiones, Quejas, Reclamos y Sugerencias presentadas por ciudadanos ante entidades publicas colombianas. Obtenido del portal de datos abiertos del Estado (datos.gov.co, id: e88e-ctba). Contiene 616 documentos reales con texto libre (asunto) y categoria administrativa, utilizado para el bloque de NLP.

3. Metodologia

Bloque 1 — Analisis Exploratorio: Carga del dataset con PySpark, limpieza y transformacion de tipos de datos. Aplicacion de tres transformaciones analiticas (filter, groupBy, withColumn+join). Calculo de estadistica descriptiva (describe, summary, percentiles). Deteccion de valores nulos (7 en municipio), duplicados (0 exactos, 24,175 llaves repetidas) y atipicos (9.96% por metodo IQR). Construccion de dos visualizaciones y redaccion de tres conclusiones cuantitativas.

Bloque 2 — Machine Learning: Construccion de pipeline de preparacion con StringIndexer, OneHotEncoder, VectorAssembler y StandardScaler. Aplicacion de PCA (32 componentes, 92.6% varianza) y K-Means con metodo del codo (K=10 optimo). Clasificacion supervisada con Regresion Logistica y Random Forest sobre 7 categorias de eventos de salud publica. Evaluacion con accuracy, precision, recall, F1 y AUC. Validacion cruzada con CrossValidator (3 folds, 4 combinaciones de hiperparametros).

Bloque 3 — NLP: Carga del corpus textual real colombiano (616 PQRS). Tokenizacion con RegexTokenizer y filtrado de 119 stop words en espanol. Estadisticas del corpus: total de tokens, vocabulario unico (types), Type-Token Ratio (TTR) e identificacion de hapax legomena. Vectorizacion TF-IDF con CountVectorizer + IDF. Clasificacion con Regresion Logistica y extraccion de coeficientes interpretables. Carga del modelo pre-entrenado pysentimiento/robertuito-sentiment-analysis de Hugging Face. Comparacion de ambos enfoques y prueba con 5 casos dificiles de lenguaje ciudadano real.

4. Hallazgos Cuantitativos

Bloque 1 — Analisis Exploratorio

Total de registros SIVIGILA procesados:	205,532
Eventos unicos de salud publica:	69
Top 1 evento (agresiones rabia):	141,156 casos
Top 2 evento (dengue):	123,641 casos
Top 3 evento (VCM/VIF/VSX):	118,469 casos
Concentracion top 3 eventos:	49.0% del total nacional
Pico de dengue (semana):	Semana 27 — 3,559 casos
Concentracion top 10 departamentos:	60.9% de los casos
Valores nulos:	7 en nom_mun (0.003%)
Registros atipicos (IQR):	20,474 (9.96%)

Bloque 2 — Machine Learning con Spark ML

Features tras OneHotEncoder:	37 (1 SEMANA + 35 dpto + 1 conteo)
Componentes PCA (90% varianza):	32 de 37
Clusters K-Means (codo):	K = 10
Accuracy Regresion Logistica:	28.4%
Accuracy Random Forest:	29.1%
Precision Random Forest:	41.0% (weighted)
F1-Score Random Forest:	0.192
AUC (OvR weighted) RF:	Reportado en notebook
Feature importance — Departamento:	68.4%
Feature importance — conteo_casos:	31.3%
Feature importance — SEMANA:	0.3%
Mejor CV (maxDepth, numTrees):	10, 50 — F1=0.1926

Bloque 3 — NLP y Hugging Face

Documentos en corpus PQRS:	616 (datos.gov.co)
Categorias tras unificacion:	9
Vocabulario unico (types):	Variable segun tokenizacion
TTR (riqueza lexica):	Moderada (textos cortos)
Hapax legomena:	~45% del vocabulario
Modelo Hugging Face:	robertuito-sentiment-analysis
Sentimiento predominante:	Mixto (POS/NEG/NEU)
Accuracy TF-IDF + LR:	Realista (no trivial)




Fig 1: Top 15 eventos SIVIGILA por casos




Fig 2: Scree plot y varianza acumulada PCA




Fig 3: Matriz de confusion TF-IDF sobre PQRS

5. Conclusiones y Recomendaciones

Conclusion 1: Concentracion de morbilidad

Tres patologías —agresiones por animales transmisores de rabia, dengue y violencia intrafamiliar/sexual— concentran el 49% de los 782,119 casos notificados al sistema SIVIGILA en 2019. Esta concentracion implica que las políticas de vigilancia epidemiológica pueden priorizar un número reducido de eventos para maximizar el impacto de los recursos limitados del sistema de salud pública.

Conclusion 2: Patrones espacio-temporales

Las enfermedades vectoriales, particularmente el dengue, exhiben un patrón estacional consistente con pico en las semanas 20-35 (coincidiendo con la temporada de lluvias). Geográficamente, 10 departamentos concentran el 60.9% de los casos, sugiriendo que tanto la carga real de enfermedad como la infraestructura de vigilancia están fuertemente concentradas en centros urbanos y departamentos con mayor capacidad instalada de salud.

Conclusion 3: Limitaciones del ML con features básicas

Con accuracy de 29.1% (vs 14% aleatorio para 7 clases), los modelos de clasificación basados únicamente en semana, departamento y conteo de casos no logran predecir con alta precisión la categoría del evento. Esto evidencia la necesidad de incorporar variables clínicas, demográficas y climáticas adicionales. El departamento de ocurrencia es el predictor más fuerte (68% de importancia), seguido del conteo de casos (31%).

Conclusion 4: NLP sobre texto ciudadano real

El corpus PQRS de datos.gov.co demuestra ser adecuado para tareas de NLP. La vectorización TF-IDF identifica correctamente los términos discriminativos de cada categoría (ej. 'parking' para Parking, 'perdidos' para Objetos Perdidos). Los coeficientes de Regresión Logística son interpretables y validan que el modelo aprende las relaciones semánticas esperadas entre palabras y categorías administrativas.

Conclusion 5: Sistema híbrido recomendado

Para un sistema de producción de atención al ciudadano, se recomienda un enfoque híbrido: (a) TF-IDF + Regresión Logística para clasificar automáticamente las PQRS en categorías administrativas y rutearlas al área correspondiente, y (b) Hugging Face (robertuito-sentiment-analysis) para priorizar por urgencia: las PQRS con sentimiento negativo y alta confianza se escalan con mayor prioridad. Este diseño combina la velocidad e interpretabilidad de TF-IDF con la capacidad de comprensión de lenguaje natural de los modelos transformer pre-entrenados.

Herramientas y Tecnologías

Python 3.11 | PySpark 4.1.1 | Spark ML (PCA, K-Means, LogisticRegression, RandomForest, CrossValidator) | Pandas, Matplotlib, Seaborn | Hugging Face Transformers (pysentimiento/robertuito-sentiment-analysis) | Jupyter Notebook | Docker | datos.gov.co (Socrata Open Data API)

Nota: Todos los notebooks, código fuente, figuras y datasets están disponibles en el repositorio del proyecto. Los notebooks se entregan ejecutados con todas las celdas y salidas visibles.