

Universidad Santo Tomás

Programa de Estadística

Machine Learning con PySpark y Docker

Tercer Corte · Semestre 2026-I

PARCIAL FINAL · Componente práctico

Profesora: Luz Adriana Gutiérrez Rodríguez

Modalidad: Individual estricto · Peso: 50% del parcial final

1. Presentación del proyecto

Este proyecto constituye el componente práctico del parcial final del curso Machine Learning con PySpark y Docker. Tiene un peso del 50% sobre el parcial final, complementado con un examen teórico que se aplicará el martes 26 de mayo y que pesa el 50% restante.

El proyecto exige que usted, de forma individual, desarrolle un análisis completo sobre datos reales colombianos, aplicando absolutamente TODO el contenido visto durante el semestre. Es lo que llamamos un análisis 360°: desde la carga del dato crudo en PySpark hasta el uso de un modelo pre-entrenado de inteligencia artificial.

A diferencia de los talleres y parciales anteriores, este proyecto le pide demostrar que ha integrado los aprendizajes de los tres cortes en una sola pieza coherente de trabajo. No se trata de hacer tres ejercicios separados, sino un análisis profundo de un fenómeno colombiano usando las herramientas adecuadas en cada paso.

Bloque 1 · Análisis exploratorio con PySpark

Tareas obligatorias

1. Cargar el dataset elegido con PySpark, mostrando el esquema, conteo de registros y primeras filas.
2. Aplicar al menos tres transformaciones (filter, groupBy, withColumn, join) que respondan a preguntas analíticas concretas.
3. Calcular estadística descriptiva: describe(), summary(), percentiles, conteos por categoría.
4. Detectar y reportar valores faltantes (nulos), duplicados y atípicos.
5. Construir al menos dos visualizaciones (después de convertir a Pandas) que sustenten conclusiones.
6. Redactar tres conclusiones cuantitativas que respondan a preguntas analíticas del dominio del dato.

Datasets sugeridos (puede elegir uno o proponer otro similar)

Dataset	Descripción	Fuente
SECOP II	Contratación pública del Estado colombiano. Contratos firmados con monto, entidad, sector y proveedor.	<i>datos.gov.co (busque 'SECOP II Procesos')</i>
Accidentalidad Bogotá	Reporte de accidentes de tránsito en Bogotá con ubicación, fecha, gravedad y tipo de vehículo.	<i>datos.gov.co (IDU / Secretaría de Movilidad)</i>

Mercado laboral DANE	Gran Encuesta Integrada de Hogares (GEIH): empleo, desempleo, informalidad por ciudad y mes.	<i>dane.gov.co / microdatos</i>
Catastro Bogotá	Información predial: avalúos, estratos, áreas y uso de los predios bogotanos.	<i>datosabiertos.bogota.gov.co</i>
ICFES Saber 11	Resultados de pruebas Saber 11 con desempeño por área, departamento, estrato.	<i>icfes.gov.co / datos abiertos</i>

Tamaño mínimo aceptable: 50.000 filas o 10.000 si las columnas son muy ricas. Si el dataset original es muy grande, puede tomar una muestra pero debe documentarlo.

Entregable del Bloque 1

Un notebook Jupyter llamado `bloque1_eda_apellido.ipynb` que contenga las seis tareas anteriores, código limpio y comentado, gráficos con títulos y etiquetas, y al final una celda Markdown con las tres conclusiones cuantitativas redactadas.

Bloque 2 · Machine Learning con Spark ML

Tareas obligatorias

Parte A · Preparación de datos (5 pts)

7. Construir un pipeline de preparación con `VectorAssembler`, `StringIndexer` y/o `OneHotEncoder` según sea necesario.
8. Aplicar normalización o estandarización (`StandardScaler` o `MinMaxScaler`) y justificar cuál eligió.

Parte B · Aprendizaje no supervisado (10 pts)

9. Aplicar PCA y reportar la varianza explicada por cada componente.
10. Decidir cuántos componentes principales conservar y justificar estadísticamente esa decisión.
11. Aplicar K-Means sobre los componentes principales. Usar el método del codo para elegir K.
12. Interpretar los clústeres encontrados: ¿qué caracteriza a cada grupo en el dominio del problema?

Parte C · Clasificación supervisada (15 pts)

13. Definir una variable objetivo (label) que tenga sentido analítico en el dataset.
14. Dividir el dataset en train (80%) y test (20%) con semilla fija.
15. Entrenar al menos dos modelos: Regresión Logística y Random Forest.
16. Reportar las métricas: accuracy, precision, recall, F1 y AUC.

17. Construir la matriz de confusión e identificar dónde el modelo se confunde más.
18. Para Random Forest: extraer la importancia de variables (feature importance) e interpretarla.

Parte D · Validación cruzada (5 pts)

19. Aplicar validación cruzada (CrossValidator) con al menos dos hiperparámetros.
20. Reportar el modelo ganador y los parámetros óptimos.

Datasets sugeridos para Bloque 2

Puede continuar con el dataset del Bloque 1 (si tiene una variable categórica clara para clasificación) o usar uno distinto. Algunas opciones que se prestan bien:

- ICFES Saber 11: predecir si un estudiante está por encima del promedio nacional.
- Accidentalidad Bogotá: predecir gravedad del accidente (leve / grave / mortal).
- Catastro Bogotá: predecir estrato a partir de variables del predio.
- Mercado laboral DANE: predecir si una persona está en informalidad laboral.

Entregable del Bloque 2

Un notebook Jupyter llamado bloque2_ml_apellido.ipynb. Debe incluir todas las celdas ejecutadas, gráficos claros (matriz de confusión, codo de K-Means, importancia de variables) y celdas Markdown que expliquen sus decisiones.

Bloque 3 · NLP y modelo pre-entrenado

Tareas obligatorias

Parte A · Preparación del corpus (8 pts)

21. Cargar un corpus textual colombiano (mínimo 200 documentos).
22. Aplicar tokenización con RegexTokenizer y filtrado de stop words en español.
23. Reportar estadística descriptiva del corpus: total de tokens, vocabulario, TTR.
24. Identificar y contar hapax legomena. Reflexionar sobre si filtrarlos o no.

Parte B · TF-IDF y análisis estadístico (10 pts)

25. Aplicar CountVectorizer + IDF para vectorizar el corpus.
26. Identificar las palabras con mayor TF-IDF promedio por categoría (si hay categorías) o globalmente.
27. Comparar el top de TF crudo con el top de TF-IDF y explicar las diferencias.

Parte C · Clasificación con TF-IDF (10 pts)

28. Definir una variable objetivo (sentimiento, categoría, tema, etc.).

29. Si el corpus no viene etiquetado: etiquetar primero con el modelo de Hugging Face (ver parte D), luego entrenar TF-IDF sobre esas etiquetas (knowledge distillation).
30. Dividir train/test con semilla fija.
31. Entrenar Regresión Logística sobre los vectores TF-IDF.
32. Evaluar con accuracy, F1 y matriz de confusión.
33. Extraer los coeficientes del modelo: ¿qué palabras predicen cada clase?

Parte D · Modelo pre-entrenado de Hugging Face (12 pts)

34. Cargar un modelo pre-entrenado de Hugging Face apropiado para el problema (recomendado: pysentimiento/robertuito-sentiment-analysis para sentimiento).
35. Aplicar el modelo a todo el corpus.
36. Comparar las predicciones del modelo pre-entrenado con las del modelo entrenado en TF-IDF.
37. Probar ambos modelos con al menos 5 casos difíciles (sarcasmo, ambigüedad, negaciones).
38. Concluir cuál enfoque recomendaría para producción y por qué.

Datasets sugeridos para Bloque 3

Dataset	Descripción	Fuente
PQRS ciudadanas	Peticiones, quejas, reclamos y sugerencias presentadas a entidades públicas.	<i>datos.gov.co (busque 'PQRS')</i>
Tweets institucionales	Comentarios públicos en redes sobre alcaldías, ministerios o eventos. Pueden hacer scraping con snsrape.	<i>Twitter/X público</i>
Reseñas de servicios	Reseñas de Google Maps o TripAdvisor sobre restaurantes, hoteles, lugares de Bogotá u otras ciudades.	<i>Google Maps API o scraping</i>
Foros ciudadanos	Comentarios en Bogotá Cómo Vamos, Concejo Bogotá Cómo Vamos, foros institucionales.	<i>Sitios institucionales</i>

Entregable del Bloque 3

Un notebook Jupyter llamado `bloque3_nlp_apellido.ipynb` con las cuatro partes ejecutadas, gráficos comparativos entre los dos enfoques (TF-IDF vs Hugging Face) y celdas Markdown que articulen sus reflexiones.

Entregables y organización del repositorio

La entrega completa consiste en un repositorio público de GitHub con la siguiente estructura mínima:

```
proyecto_final_apellido_nombre/ ├── README.md ├── bloque1_eda/ |   |   ├── bloque1_eda_apellido.ipynb |   |   ├── (archivos auxiliares opcionales) |   |   └── bloque2_ml/ |   |       |   |       ├── bloque2_ml_apellido.ipynb |   |       ├── (modelos guardados opcionales) |   |       └── bloque3_nlp/ |   |           |   |           ├── bloque3_nlp_apellido.ipynb |   |           ├── corpus.csv (si aplica) |   |           └── reporte_ejecutivo.pdf |   └── docker-compose.yml (obligatorio)
```

Contenido obligatorio del README.md

39. Nombre completo del estudiante.
40. Descripción del problema escogido (1-2 párrafos).
41. Datasets utilizados en cada bloque, con sus fuentes oficiales.
42. Cómo ejecutar los notebooks (versión de Python, dependencias, orden de ejecución).
43. Conclusión integrada (un párrafo de 5-8 líneas que conecte los tres bloques).

Reporte ejecutivo (PDF de 2-3 páginas)

Un documento PDF redactado en formato profesional con la siguiente estructura:

- Resumen ejecutivo: descripción del problema y hallazgos principales (medio párrafo).
- Metodología: qué hizo en cada uno de los tres bloques y por qué.
- Resultados clave: tres hallazgos cuantitativos, uno por bloque, con números específicos.
- Reflexión integradora: cómo se conectaron las tres técnicas para responder al problema.
- Limitaciones: dos o tres limitaciones honestas de su análisis.
- Recomendaciones: qué le diría a alguien que quiere replicar o continuar este análisis.

10. Recomendaciones finales

Sobre la elección de los datasets

- Elija datasets que tengan suficiente volumen y calidad. Un dataset con 100 registros no permite hacer ML serio.
- Verifique que el dataset tiene las columnas que necesita ANTES de invertir tiempo en él.
- Para el bloque de NLP, asegúrese de tener una columna de texto rica (no titulares cortos).
- Si no encuentra etiquetas para el corpus del Bloque 3, use el modelo de Hugging Face para etiquetar (knowledge distillation, lo vimos en clase).

Sobre el código

- Use celdas Markdown para explicar lo que hace cada bloque de código.
- Nombre las variables de forma descriptiva: prefiera `df_accidentes` a `df1`.
- Antes de entregar: Restart and Run All. Si algo falla, arréglo. No entregue con errores.
- Comente decisiones metodológicas importantes en celdas Markdown, no solo en comentarios de código.

Sobre el reporte ejecutivo

- Escriba para alguien que NO leyó sus notebooks. Debe entenderse de forma independiente.
- Cite números específicos: "accuracy de 0.87" es mejor que "buen desempeño".
- Mencione las limitaciones honestamente: muestra madurez analítica.
- Conecte los tres bloques al final: ¿qué historia cuentan juntos?

Sobre el uso de IA generativa

Se permite usar herramientas como ChatGPT, Claude, GitHub Copilot para resolver dudas puntuales sobre sintaxis o errores. NO se permite delegar el análisis completo. La profesora pedirá explicaciones orales sobre cualquier sección del notebook durante la sustentación virtual: si no puede explicar lo que su código hace, se considera plagio.

Sobre las consultas

Las sesiones del lunes 26 (sesión 31) y miércoles 28 (sesión 32) están reservadas para asesorías. Aproveche para resolver dudas conceptuales y técnicas. También puede escribirme por el canal del curso. Las dudas en grupo o pequeños grupos son bienvenidas, las copias se penalizan con cero.